


UNIVERSIDADE FEDERAL DO PARANÁ
SETOR DE CIÊNCIAS EXATAS
CURSO DE CIÊNCIA DA COMPUTAÇÃO

MARIA TERESA KRAVETZ ANDRIOLI

TÍTULO

CURITIBA

2022



MARIA TERESA KRAVETZ ANDRIOLI

TITULO

Trabalho apresentado como requisito parcial para a obtenção do grau de Bacharel em Ciência da Computação no curso de Ciência da Computação, Setor de Ciências Exatas da Universidade Federal do Paraná.

Orientador: Prof. Dr. Luiz Carlos P. Albini

CURITIBA

2022

TERMO DE APROVAÇÃO

MARIA TERESA KRAVETZ ANDRIOLI

TITULO

Trabalho apresentado como requisito parcial para a obtenção do grau de Bacharel em Ciência da Computação no curso de Ciência da Computação, Setor de Ciências Exatas da Universidade Federal do Paraná, pela seguinte banca examinadora:

Prof. Dr. Luiz Carlos P. Albini
Orientador

Professora
UFPR

Professora

Professora

Curitiba, Maio de 2022.

*Este trabalho é dedicado às crianças adultas que,
quando pequenas, sonharam em se tornar cientistas.*

AGRADECIMENTOS

Os agradecimentos principais são direcionados à Gerald Weber, Miguel Frasson, Leslie H. Watter, Bruno Parente Lima, Flávio de Vasconcellos Corrêa, Otavio Real Salvador, Renato Machnievscz¹ e todos aqueles que contribuíram para que a produção de trabalhos acadêmicos conforme as normas ABNT com \LaTeX fosse possível.

Agradecimentos especiais são direcionados ao Centro de Pesquisa em Arquitetura da Informação² da Universidade de Brasília (CPAI), ao grupo de usuários *latex-br*³ e aos novos voluntários do grupo *abnT_EX2*⁴ que contribuíram e que ainda contribuirão para a evolução do *abnT_EX2*.

Os agradecimentos principais são direcionados à Gerald Weber, Miguel Frasson, Leslie H. Watter, Bruno Parente Lima, Flávio de Vasconcellos Corrêa, Otavio Real Salvador, Renato Machnievscz⁵ e todos aqueles que contribuíram para que a produção de trabalhos acadêmicos conforme as normas ABNT com \LaTeX fosse possível.

¹ Os nomes dos integrantes do primeiro projeto *abnT_EX* foram extraídos de <http://codigolivre.org.br/projects/abntex/>

² <http://www.cpai.unb.br/>

³ <http://groups.google.com/group/latex-br>

⁴ <http://groups.google.com/group/abntex2> e <http://abntex2.googlecode.com/>

⁵ Os nomes dos integrantes do primeiro projeto *abnT_EX* foram extraídos de <http://codigolivre.org.br/projects/abntex/>

RESUMO

O resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. O resumo deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento. (...) As palavras-chave devem figurar logo abaixo do resumo, antecedidas da expressão Palavras-chave:, separadas entre si por ponto e finalizadas também por ponto. Ter no máximo 500 palavras!!! As palavras chave são separadas por ponto e vírgula.

Palavras-chaves: latex; abntex; editoração de texto.

ABSTRACT

This is the english abstract.

Key-words: latex. abntex. text editoration.

LISTA DE CÓDIGOS

2.1	Exemplo de função Map em pseudocódigo adaptado de (DEAN; GHEMAWAT, 2008)	13
2.2	Exemplo de função Reduce em pseudocódigo adaptado de (DEAN; GHEMAWAT, 2008)	13

LISTA DE ILUSTRAÇÕES

FIGURA 1 – EXECUÇÃO GENÉRICA DO MAPREDUCE	14
FIGURA 2 – EXEMPLO DE EXECUÇÃO DO MAPREDUCE	15
FIGURA 3 – NOVA ARQUITETURA DO HADOOP 2.0	18
FIGURA 4 – ARQUITETURA DOCKER	19

SUMÁRIO

1	INTRODUÇÃO	10
1.1	CONTEXTO	10
1.2	OBJETIVO	11
1.3	ESTRUTURA DO TRABALHO	11
2	REFERENCIAL TEÓRICO	12
2.1	CLUSTERS	12
2.2	MAPREDUCE	12
2.2.1	Modelo de programação	13
2.2.2	Execução do MapReduce	14
2.3	HADOOP	15
2.3.1	Hadoop Common	16
2.3.2	Hadoop HDFS	16
2.3.3	Hadoop MapReduce	17
2.3.4	Hadoop YARN	17
2.4	DOCKER	17
	REFERÊNCIAS	20

1 INTRODUÇÃO

1.1 CONTEXTO

O uso, armazenamento e controle de dados é um tema muito discutido na área de computação desde seus primórdios até os dias de hoje. Por causa disso, muitos métodos e algoritmos e termos surgiram ao longo do tempo com o objetivo de gerenciar de forma eficiente esses dados. O surgimento dessas novas ferramentas computacionais e métodos de armazenamento foi importantíssimo para a evolução da área.

Atualmente, os métodos mais comuns são os bancos de dados relacionais e *datas warehouses* usando computação em nuvem (KUO; KUSIAK, 2019). Além disso, pesquisas nos campos de mineração de dados e aprendizagem de máquina cresceram bastante recentemente de modo a prover técnicas que permitissem analisar dados complexos e variados entre si (BELCASTRO et al., 2022). Um grande desafio é o fato de algoritmos sequenciais não serem otimizados o suficiente para lidar com dados em grande quantidade. Por causa disso, computadores de alta performance, com múltiplos *cores*, sistemas na nuvem e algoritmos paralelos e distribuídos são usados para lidar com esses empecilhos de *Big Data* (BELCASTRO et al., 2022).

Big Data refere-se a grandes conglomerados de dados complexos sobre os quais não é possível aplicar ferramentas tradicionais de processamento, armazenamento ou análise (KHA-LEEL; AL-RAWESHIDY, 2018). Estima-se que em 2025, os dados atuais criados, capturados ou replicados atinjam 175 Zettabytes, ou seja 175,000,000,000 Gigabytes (RYDNING, 2018).

A fim de lidar com essa enorme quantidade de dados, foi desenvolvido pelo Google o *MapReduce*, que é um modelo com uma implementação associada feito para processar e gerar grandes conglomerados de dados. Esse modelo é inspirado nos conceitos de mapear e reduzir, ou seja, aplicar uma operação que conecta cada item da base de dados a um determinado par de chaves e valores e então aplicar uma operação de reduzir, que junta os valores que compartilham chaves (DEAN; GHEMAWAT, 2008). Com essas operações é possível paralelizar dados em grandes quantidades e utilizar mecanismos de reutilização para facilitar a busca e manipulação destes.

Um dos *frameworks* mais populares que utiliza o *MapReduce* é o *Hadoop*, que foi desenvolvido pela Apache em 2006 e é capaz de armazenar e processar de giga a petabytes de dados eficientemente. Essa ferramenta é capaz de fazer isso optando por usar múltiplos computadores (*clusters*) em paralelo (WHITE, 2015).

1.2 OBJETIVO

O *Hadoop MapReduce* é um *framework* extremamente personalizável e adaptável. Por causa disso, frequentemente usa-se o processo de *tuning*, que consiste em modificar os mais de 190 parâmetros desse *framework* de modo a maximizar a eficiência de um *cluster Hadoop*. Esses parâmetros podem ser alterados em diversas combinações e podem ter efeitos tanto no *cluster* quanto nas tarefas (*jobs*) do processo.

Esse trabalho tem como objetivo avaliar o comportamento do *Hadoop MapReduce* antes e depois do *tuning* de alguns parâmetros de configuração, observando através de métricas de *benchmark* se houve melhora na performance considerando medidas como tempo e uso de memória.

1.3 ESTRUTURA DO TRABALHO

[TODO: ESTRUTURA DO TRABALHO]

2 REFERENCIAL TEÓRICO

Esse capítulo tem como objetivo apresentar detalhadamente os conceitos técnicos que serão utilizados ao longo do trabalho. A seção 2.1 introduz o conceito de *clusters*. A seção 2.2 apresenta o *MapReduce*, o modelo de manipulação de dados feito pelo Google e a seção 2.3 trata do *Hadoop*, o *framework* desenvolvido pela Apache. Por fim, a seção 2.4 explica virtualização, contêineres e a ferramenta Docker.

2.1 CLUSTERS

Um *cluster* é um conjunto de computadores que trabalham juntos paralelamente em uma determinada aplicação. Cada computador desse conjunto é usualmente chamado de nodo. Além disso, existem diversas categorias de clusters dependendo do problema que eles buscam computar.

Algumas aplicações comuns de *clusters* são modelagem de clima, simulação de acidentes automotivos, mineração de dados e aplicações da área de astrofísica. Além disso, é comumente visto em aplicações comerciais como bancos e serviços de email (SADASHIV; KUMAR, 2011).

Uma das maiores vantagens desse tipo de instalação é a tolerância de falhas, pois os sistemas conseguem continuar suas tarefas caso um nodo pare de funcionar. Ainda, é altamente escalável com a adição de novos nodos, não precisa de manutenção frequente e tem um gerenciamento centralizado. Por fim, uma das suas maiores possíveis vantagens é o balanceamento de carga, que busca atingir o equilíbrio entre as tarefas de cada nodo de modo a otimizar os recursos.

2.2 MAPREDUCE

MapReduce é um modelo de programação associado a uma implementação que tem como objetivo processar, manipular e gerar grandes *datasets* de modo eficiente, escalável e com aplicações no mundo real. As computações acontecem de acordo com funções de mapeamento e redução e o sistema do *MapReduce* paraleliza essas computações entre grandes *clusters*, lidando com possíveis falhas, escalonamentos e uso eficiente de rede e discos (DEAN; GHEMAWAT, 2008).

As operações de mapeamento e redução são baseadas em conceitos presentes em linguagens funcionais e fazem com que seja possível fazer diversas reutilizações, assim lidando com tolerância de falhas (DEAN; GHEMAWAT, 2008).

2.2.1 Modelo de programação

A computação recebe um conjunto de pares (VALOR, CHAVE) e produz um conjunto de pares de (VALOR, CHAVE). O usuário cria as funções *Map* e *Reduce* de acordo com seu caso de uso. *Map* recebe um único par (VALOR, CHAVE) e produz um conjunto intermediário de pares. Em seguida, a biblioteca *MapReduce* agrupa os valores com a mesma chave e esses valores servirão de entrada para a função *Reduce*. A função *Reduce* então junta os valores com a mesma chave de modo a criar um conjunto menor, sendo possível dessa forma lidar com listas muito grandes para a memória disponível (DEAN; GHEMAWAT, 2008). Entre o momento que são executadas as funções *Map* e *Reduce*, existe a fase *Shuffle*, que é criada automaticamente em tempo de execução e executa operações de ordenação (*sort*) e junção (*merge*) (VENNER, 2009). Ainda, segundo White (2015), a operação *Shuffle* é um dos fatores mais influentes no bom desempenho de aplicações *MapReduce*, já que operações de ordenação e junções podem prejudicar ou melhorar muito um algoritmo conforme sua implementação.

Como exemplo, considere o problem de contar quantas vezes determinada palavra aparece em um documento. Nesse problema, as funções *Map* e *Reduce* seriam similares aos seguintes pseudocódigos (DEAN; GHEMAWAT, 2008):

```

1 map(String chave, String valor):
2   // chave: nome do documento
3   // valor: conteudo do documento
4
5   para cada palavra W em valor:
6     criaIntermediario(W, 1);

```

CÓDIGO 2.1 – Exemplo de função Map em pseudocódigo adaptado de (DEAN; GHEMAWAT, 2008)

```

1 reduce(String chave, Iterador valores):
2   // chave: uma palavra
3   // valores: lista de contagens
4
5   int resultado = 0;
6   para cada V em valores:
7     resultado = resultado + 1;
8   cria(resultado);

```

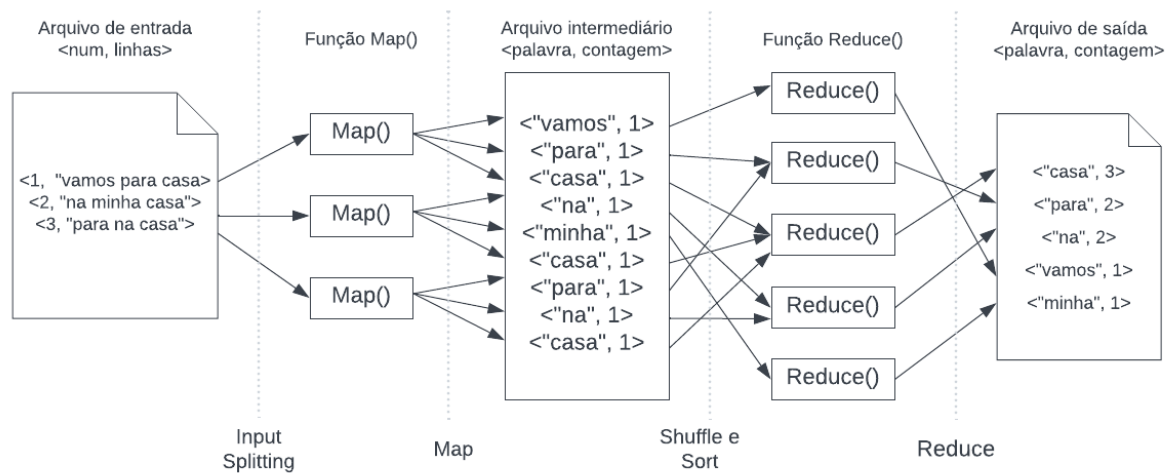
CÓDIGO 2.2 – Exemplo de função Reduce em pseudocódigo adaptado de (DEAN; GHEMAWAT, 2008)

A função *Map* gera um objeto intermediário de cada palavra associada a uma lista do

seu número de ocorrências no texto e a função *Reduce* soma os valores até ter o total de ocorrências por palavra. Além disso, o usuário cria uma configuração de *MapReduce* com os parâmetros de entrada e saída e eventuais parâmetros de *tuning*.

Para exemplificar ainda mais, considere um arquivo de texto com três linhas nas quais estão as seguintes frases, respectivamente, uma em cada linha: "vamos para casa", "na minha casa", "para na casa". Nesse exemplo, a função *Map* é chamada três vezes, uma para cada linha, gerando os pares (CHAVE, VALOR) intermediários, um para cada palavra encontrada no texto, como é exemplificado na FIGURA 1. Para cada palavra distinta ("vamos", "para", "casa", "na", "minha"), é executada a função *Reduce*, que soma quantas vezes cada uma dessas palavras apareceu no texto e gera um arquivo de saída.

FIGURA 1 – EXECUÇÃO GENÉRICA DO MAPREDUCE



FONTE: A autora (2022)

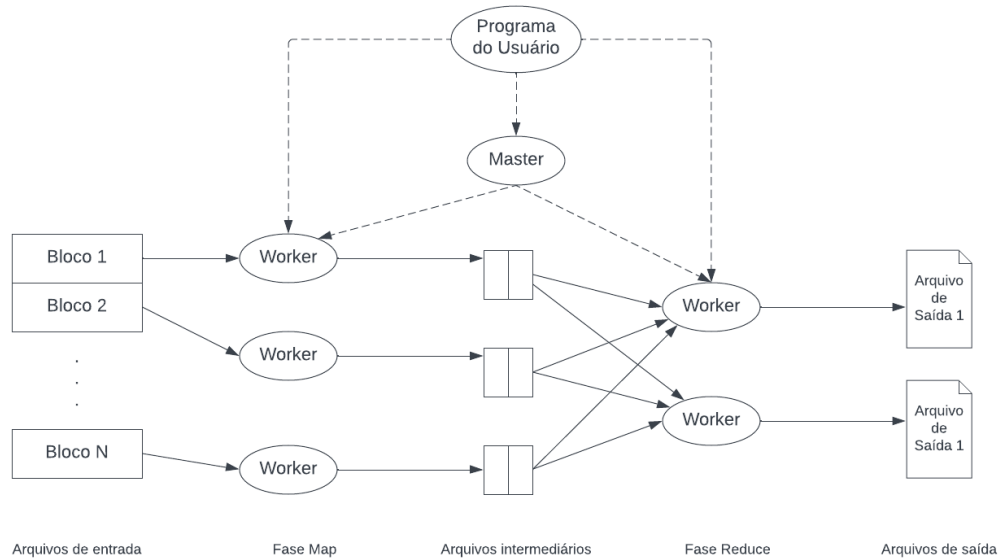
2.2.2 Execução do MapReduce

O *MapReduce* funciona usando uma estrutura Cliente/Servidor sobre um *cluster*, que segundo Dean e Ghemawat (2008) consiste em primeiramente particionar os dados de entrada em bloco de tamanho já definidos e distribuir cópias do programa MapReduce entre cada um desses blocos. Existe uma cópia Master, que é responsável por distribuir as tarefas (*tasks*). O restante das cópias são denominadas Workers e elas recebem da Master as tarefas junto com os arquivos de entrada. Ao finalizar a execução de uma tarefa do tipo *Map*, a cópia Worker responsável repassa à Master os arquivos de saída e esta repassa à um Worker esse arquivo com a tarefa de *Reduce*. Então, esse worker executa a redução, lendo os pares intermediários que passaram pela fase *Shuffle* e agrupando as instâncias de mesma chave. Quando todas as tarefas *Map* e *Reduce* forem executadas, o programa é finalizado.

Na FIGURA 1 foi possível ver como o *MapReduce* funcionaria em pequena escala. Uma das maiores vantagens do *MapReduce* é, no entanto, sua escalabilidade, visto que ele permite

uma execução distribuída entre uma grande quantidade de nodos. A FIGURA 2 representa uma execução genérica do *MapReduce*, descrita no parágrafo acima.

FIGURA 2 – EXEMPLO DE EXECUÇÃO DO MAPREDUCE



FONTE: Adaptado de (DEAN; GHEMAWAT, 2008)

2.3 HADOOP

Hadoop é um *framework* desenvolvido na linguagem Java pela Apache Software Foundation com os seguintes princípios arquiteturais, segundo Navarro Belmonte (2018):

- A possibilidade de escalar o sistema ao adicionar nodos no *cluster*.
- Possibilidade de funcionar bem em *hardware* não necessariamente caro e de luxo.
- Tolerância a falhas, com implementações que identificam estas e permitem que o sistema funcione independente delas acontecerem.
- Fornecimento de serviços transparentes de modo que o usuário possa focar no problema que ele quer resolver.

Esse *framework* disponibiliza ferramentas para que o usuário possa escrever as funções necessárias em diversas linguagens de programação, conforme a necessidade do programador. O *framework* funciona na mesma estrutura de Cliente/Servidor apresentada anteriormente e que é usada pelo *MapReduce*. Além disso, oferece ao programador um sistema paralelo e distribuído (*Hadoop HDFS*), com os recursos ocultos do usuário, mas capaz de lidar com a comunicação entre as máquinas, quaisquer falhas que possam vir a ocorrer e o escalonamento das tarefas.

Além do *Hadoop Map Reduce* e do *Hadoop HDFS*, existem outros subprojetos do Hadoop que compõem sua estrutura principal: o *Hadoop Common*, que fornece ferramentas comuns aos outros subprojetos e *Hadoop YARN*, um *framework* para escalonamento de tarefas e gerenciamento de recursos em *clusters*.

2.3.1 Hadoop Common

Esse subprojeto contém os utilitários e bibliotecas comuns aos outros subprojetos. Por exemplo, funções de manipulação de arquivos, funções auxiliares de serialização de dados, etc.

2.3.2 Hadoop HDFS

Segundo Borthakur (2020) o *Hadoop HDFS* é um sistema de arquivos distribuídos feito para funcionar em *hardware* facilmente obtido e relativamente barato. Suas características principais são a alta capacidade de lidar com falhas e a possibilidade de ser usado com aplicações que tem grande quantidades de dados como entrada.

Uma instância HDFS é composta de centenas ou milhares de máquinas, cada um responsável por armazenar uma parte dos dados do sistema. Por causa disso, rápida detecção e recuperação de falhas é essencial para sua estrutura. Seu *design* foi pensado em aplicações de processamento de dados em blocos e seus arquivos de entrada possuem tamanhos enormes, variando de giga a terabytes. Além disso, é adaptado para funcionar em diferentes plataformas e provê interfaces que possibilitam mover a aplicação para perto dos dados, pois esse fato faz com que qualquer operação computacional aplicada seja muito mais eficiente (BORTHAKUR, 2020).

O *Hadoop HDFS* também possui uma estrutura Cliente/Servidor, onde o *Namenode* é o nodo Master e os *Datanodes* são os nodos Worker. O *Namenode* é responsável por gerenciar o sistema e regular o acessos aos arquivos. Os *Datanodes* são responsáveis por gerenciar o armazenamento dos nodos aos quais eles estão conectados. O sistema é implementado usando uma estrutura comum de diretórios na qual é possível criar, mover, renomear e remove arquivos e diretórios, mas ainda não implementada funções como quota de usuários, permissões de acesso ou links simbólicos (BORTHAKUR, 2020).

Uma das características essenciais desse sistema é sua capacidade de lidar com grandes quantidades de dados. Segundo Borthakur (2020), isso é feito através do armazenamento dos arquivos como uma sequência de blocos, cujo tamanho e fator de replicação são configuráveis pelo usuário, mas possuem um valor padrão de 64MB. Periodicamente, o *Namenode* recebe dos *Datanodes* um sinal indicando se o funcionamento está correto. O posicionamento e quantidade de réplicas de um bloco é crítica na análise da boa performance do HDFS, e é um dos fatores que o diferencia de outros sistemas de arquivos distribuídos. Se bem feita, pode aumentar confiabilidade, disponibilidade e uso de redes do sistema.

2.3.3 Hadoop MapReduce

O *Hadoop MapReduce* é um *framework* que implementa o modelo de programação *MapReduce* para que seja fácil criar aplicações que são capazes de processar grandes quantidades de dados em paralelo em *clusters* de uma forma confiável e com tolerância a falhas.

Esse *framework* é constituído de um *Job* responsável por dividir os arquivos de entrada em blocos independentes que serão processados pelas tarefas (*tasks*) *Map*, ordenados na fase *Shuffle* e inseridos nas tarefas *Reduce* de forma paralela. Os arquivos de entrada e saída são armazenados no sistema de arquivos e o sistema é responsável pelo escalonamento, agendamento e reexecução de tarefas que tenham falhado (MAPREDUCE. . . , 2022).

A estrutura Cliente/Servidor tem como nodo Master o *JobTracker* e como nodos Worker os *TaskTrackers*. Como já visto, o nodo Master designa as tarefas e os nodos Worker as executam. A aplicação do programador fornece o local dos arquivos de entrada e saída, a implementação das funções de *Map* e *Reduce* e outros parâmetros de configuração do *Job*. Então, o cliente *Hadoop* envia o *Job* e o arquivo de configuração para o *JobTracker* que distribui as tarefas e controla o funcionamento desse *Job*.

2.3.4 Hadoop YARN

O *Hadoop YARN* é um subprojeto que tem como objetivo dividir as funcionalidade de gerenciamento de recursos de escalonamento de tarefas em módulos diferentes tendo, então, um gerenciador global de recursos de um gerenciado local por aplicação.


O gerenciador global trabalha em conjunto com um gerenciador de nodos que é responsável pelos contêineres e pelo monitoramento de uso de recursos, como CPU, memória, uso de disco e uso de redes, assim como o repasse dessas informações para o gerenciador global (APACHE. . . , 2022).

O YARN foi adicionado ao *Hadoop* versão 2.0 e com isso permitiu que exista a separação das camadas de gerenciamento de recursos e que estes pudessem ser alocados pela aplicação. Com essa camada independente, como é visto na FIGURA 3 é possível que aplicações *MapReduce* possam ser utilizadas em conjunto com aplicações não *MapReduce*. Além disso, esse formato de implementação possibilita economizar custos com o melhor aproveitamento dos nodos (KOBYLINSKA; MARTINS, 2014).

2.4 DOCKER

Virtualização é o processo de criar um ambiente ou uma versão virtual de algum componente computacional, tal como *hardwares*, dispositivos de armazenamento e recursos de rede. A virtualização permite que haja economia nos custos de *hardware*, melhoria na recuperação em caso de falhas e redução da necessidade de espaço físico para *datacenters*. Uma das técnicas da virtualização é a utilização de contêineres. Contêineres, uma virtualização a nível

FIGURA 3 – NOVA ARQUITETURA DO HADOOP 2.0



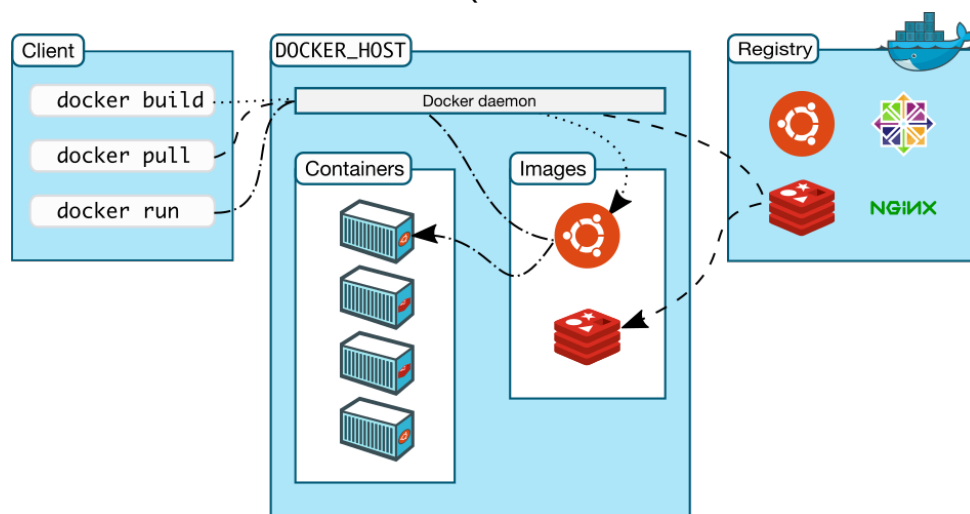
FONTE: (KOBYLINSKA; MARTINS, 2014)

de sistema, permite que existam múltiplos espaços do usuário por cima de um determinada kernel de sistema.

Docker é uma ferramenta que tem como objetivo automatizar a implantação de aplicações em contêineres. Essa ferramenta empilha uma implantação de uma aplicação em cima de um ambiente de execução em um contêiner. Ou seja, simula um ambiente virtual de modo que o programador possa trabalhar com sua aplicação em produção de forma extremamente configurável para as necessidades dele. Para fazer isso, o Docker utiliza um recurso de imagem, que nada mais é que uma referência aos arquivos de sistemas que determinada aplicação necessita para ser executada. Esse arquivos são, então, empilhados um em cima do outro e servem como uma receita para construção de um ou múltiplos contêineres (TURNBULL, 2014). Na FIGURA 4 está exemplificado a estrutura geral da arquitetura do Docker.

Nesse trabalho será utilizada a imagem do Hadoop distribuída pela Apache de modo que o framework possa ser devidamente simulado, configurado e testado.

FIGURA 4 – ARQUITETURA DOCKER



FONTE: (DOCKER..., 2022)

REFERÊNCIAS

- APACHE Hadoop YARN. [S.l.: s.n.], 2022. Disponível em: <https://hadoop.apache.org/docs/stable/hadoop-yarn/hadoop-yarn-site/YARN.html>. Citado 1 vez na página 17.
- BELCASTRO, L.; CANTINI, R.; MAROZZO, F.; ORSINO, A.; TALIA, D.; TRUNFIO, P. Programming big data analysis: principles and solutions. **Journal of Big Data**, SpringerOpen, v. 9, n. 1, p. 1–50, 2022. Citado 2 vez na página 10.
- BORTHAKUR, D. **HDFS architecture guide**. [S.l.: s.n.], out. 2020. Disponível em: https://hadoop.apache.org/docs/r1.2.1/hdfs_design.html. Citado 4 vez na página 16.
- DEAN, J.; GHEMAWAT, S. MapReduce: simplified data processing on large clusters. **Communications of the ACM**, ACM New York, NY, USA, v. 51, n. 1, p. 107–113, 2008. Citado 12 vezes nas páginas 7, 10, 12–15.
- DOCKER Overview. [S.l.]: Docker Inc., abr. 2022. Disponível em: <https://docs.docker.com/get-started/overview/>. Citado 0 vez na página 19.
- KHALEEL, A.; AL-RAWESHIDY, H. Optimization of computing and networking resources of a Hadoop cluster based on software defined network. **IEEE Access**, IEEE, v. 6, p. 61351–61365, 2018. Citado 1 vez na página 10.
- KOBYLINSKA, A.; MARTINS, F. **Big data tools for midcaps and others**. [S.l.: s.n.], 2014. Disponível em: <https://www.admin-magazine.com/Archive/2014/20/Big-data-tools-for-midcaps-and-others>. Citado 1 vezes nas páginas 17, 18.
- KUO, Y.-H.; KUSIAK, A. From data to big data in production research: the past and future trends. **International Journal of Production Research**, Taylor & Francis, v. 57, n. 15-16, p. 4828–4853, 2019. DOI: [10.1080/00207543.2018.1443230](https://doi.org/10.1080/00207543.2018.1443230). eprint: <https://doi.org/10.1080/00207543.2018.1443230>. Disponível em: <https://doi.org/10.1080/00207543.2018.1443230>. Citado 1 vez na página 10.
- MAPREDUCE Tutorial. [S.l.: s.n.], 2022. Disponível em: https://hadoop.apache.org/docs/r1.2.1/mapred_tutorial.html. Citado 1 vez na página 17.

NAVARRO BELMONTE, V. P. **Improving Real Time Tuning on YARN**. 2018. Tese (Doutorado) – Carleton University. Citado 1 vez na página 15.

RYDNING, D. R.-J. G.-J. The digitization of the world from edge to core. **Framingham: International Data Corporation**, p. 16, 2018. Citado 1 vez na página 10.

SADASHIV, N.; KUMAR, S. D. Cluster, grid and cloud computing: A detailed comparison. In: IEEE. 2011 6th international conference on computer science & education (ICCSE). [S.l.: s.n.], 2011. P. 477–482. Citado 1 vez na página 12.

TURNBULL, J. **The Docker Book: Containerization is the new virtualization**. [S.l.]: James Turnbull, 2014. Citado 1 vez na página 18.

VENNER, J. **Pro hadoop**. [S.l.]: Apress, 2009. Citado 1 vez na página 13.

WHITE, T. **Hadoop: The definitive guide**. [S.l.]: "O'Reilly Media, Inc.", 2015. Citado 2 vezes nas páginas 10, 13.